



课程实验报告

探索实验 环境声音分类

课程名称	信号与系统
专业名称	计算机科学与技术
小组成员	陈政宇、程嘉耀、甘善铭、陈湔泉
实验地点	教学大楼-B202
实验成绩	
实验日期	2025 年 6 月 3 日

目录

1 摘要	4
2 小组分工	4
3 数学模型	5
3.1 音频信号预处理	5
3.1.1 信号采样与标准化	5
3.2 短时傅立叶变换 (STFT)	5
3.2.1 STFT 数学模型	5
3.2.2 窗函数设计	6
3.2.3 幅度谱计算	6
3.3 Mel 频率变换	7
3.3.1 Mel 刻度转换	7
3.3.2 Mel 滤波器组设计	7
3.3.3 Mel 频谱计算	7
3.4 机器学习模型	8
3.4.1 卷积神经网络 (CNN) 模型	8
3.4.2 ResNet 残差网络模型	9
3.4.3 注意力机制网络模型	9
3.4.4 孪生网络模型	10
3.4.5 损失函数	11
3.4.6 优化算法	11
3.4.7 模型复杂度对比	11
4 数据分析处理	12
4.1 ESC-50 数据集概述	12
4.1.1 数据集基本信息	12
4.1.2 声学特征分析标准	12
4.2 数据预处理流程	13
4.2.1 信号预处理步骤	13
4.2.2 时频变换处理	13
4.3 典型声音类别对比分析	13
4.3.1 人声类音频分析	13
4.3.2 物理噪声类音频分析	14
4.3.3 动物噪声类音频分析	15
4.4 Mel 滤波器效果评估	15
4.4.1 优势分析	15
4.4.2 局限性分析	16

4.4.3 特征提取效果量化	16
4.5 数据处理结论	16
5 模型训练评估	16
5.1 评估指标体系	17
5.1.1 分类性能指标	17
5.1.2 混淆矩阵分析	17
5.2 实验设置	18
5.2.1 数据集划分	18
5.2.2 训练配置参数	18
5.2.3 正则化策略	18
5.3 训练过程分析	18
5.3.1 损失函数收敛性	18
5.3.2 收敛特性分析	19
5.4 性能评估结果	19
5.4.1 整体性能对比	19
5.5 模型复杂度分析	20
5.5.1 计算复杂度对比	20
5.5.2 效率-性能平衡分析	20
5.5.3 性能优势分析	21
5.5.4 误分类分析	22
5.5.5 改进方向	22
5.6 本章小结	23
6 感想	23
7 参考文献	26

1 摘要

环境声音分类作为音频信号处理领域的重要研究方向，在智能监控、环境感知和人机交互等应用中具有广泛的实用价值。本项目基于 ESC-50 开源环境声音数据集，构建了一个完整的环境声音自动分类系统。

系统采用短时傅立叶变换(STFT)对时域音频信号进行时频域转换，通过 Mel 滤波器组将线性频谱映射至符合人耳感知特性的 Mel 频率刻度，提取对数 Mel 频谱图作为音频特征表示。该特征提取方法充分利用了人类听觉系统的感知机制，在低频区域保持高分辨率，在高频区域适当降低分辨率，有效压缩了特征维度的同时保留了关键的音频信息。

在机器学习模型方面，本项目实现并对比了多种分类算法的性能表现，包括传统机器学习方法和深度学习模型。通过在 ESC-50 数据集上的实验验证，系统能够有效识别动物声音、自然声音、人为声音、室内外声音等 50 类环境声音，为环境声音的自动识别与分类提供了可行的技术方案。

本项目的贡献包括：

- (1) 构建了完整的环境声音分类 pipeline，从数据预处理到模型训练的全流程实现；
- (2) 深入分析了 STFT 和 Mel 频谱变换的数学原理及其在音频特征提取中的应用；
- (3) 系统性比较了不同分类算法在环境声音识别任务上的性能差异。

研究结果表明，基于 Mel 频谱特征的深度学习方法在环境声音分类任务中具有良好的分类精度和泛化能力。

关键词：环境声音分类；短时傅立叶变换；Mel 频谱；机器学习；ESC-50 数据集

2 小组分工

学号	姓名	主要负责内容
23336003	陈政宇	项目总体架构设计、论文撰写
23330018	程嘉耀	模型构建及数学推导
23336005	甘善铭	数据集处理及分析
22335009	陈淏泉	机器学习模型训练与评估

图 2.0.1: 小组成员分工情况

3 数学模型

3.1 音频信号预处理

为保证后续实验的一致性和可比性，需要对原始音频信号进行预处理。既符合机器学习模型的输入要求，又能保证数值的稳定性。

3.1.1 信号采样与标准化

设原始音频信号为连续时间信号 $x(t)$ ，经过采样频率 $f_s = 22050$ Hz 的均匀采样后得到离散时间信号：

$$x[n] = x(nT_s), \quad n = 0, 1, 2, \dots \quad (3.1)$$

其中 $T_s = \frac{1}{f_s}$ 为采样周期。

为确保输入信号长度一致性，对音频信号进行固定长度截取或零填充[1]：

$$x_{\text{norm}}[n] = \begin{cases} x[n] & \text{if } n < L \\ 0 & \text{if } n \geq L \text{ and } |x| < L \\ x[n] & \text{if } n < L \text{ and } |x| \geq L \end{cases} \quad (3.2)$$

其中 $L = f_s \times T_{\text{dur}} = 22050 \times 5 = 110250$ 为目标信号长度， $T_{\text{dur}} = 5$ s 为音频时长。

3.2 短时傅立叶变换 (STFT)

短时傅里叶变换（STFT）是经典的时频分析方法[2]。考虑到直接对音频信号进行傅立叶变换处理会丢失音频信号在时域上的信息，而时域信息对于分辨一个声音而言也是十分重要的，因此我们采用短时傅立叶变换（STFT）对音频信号进行时频域转换，同时提取声音信号在时域和频域上的特征。

STFT 流程为：对长信号分帧、加窗（见下文），再对每一帧做傅里叶变换（FFT），最后将每一帧的频谱结果沿时间轴堆叠，得到二维的时频谱图。STFT 的每一步都依赖于前面的加窗操作。

3.2.1 STFT 数学模型

短时傅立叶变换通过滑动窗口对信号进行局部频谱分析[2]，其数学表达式为：

$$X(m, k) = \sum_{n=0}^{N-1} x[n + mH] \cdot w[n] \cdot e^{-j2\pi k \frac{n}{N}} \quad (3.3)$$

其中：

- m 为时间帧索引
- k 为频率 bin 索引, $k = 0, 1, \dots, \frac{N}{2}$
- H 为帧移 (hop length), 取值 $H = 512$
- N 为 FFT 窗口长度, 取值 $N = 2048$
- $w[n]$ 为窗函数

3.2.2 窗函数设计

本系统采用汉宁窗 (Hann Window) 进行加窗处理[3]:

$$w[n] = 0.5 \left(1 - \cos \left(\frac{2\pi n}{N-1} \right) \right), \quad n = 0, 1, \dots, N-1 \quad (3.4)$$

汉宁窗具有良好的频谱泄漏抑制特性, 其主瓣宽度为 $4\frac{\pi}{N}$, 旁瓣峰值约为-31.5 dB。




图 3.2.1: hann 函数示意图

3.2.3 幅度谱计算

STFT 结果为复数矩阵, 计算其幅度谱:

$$|X(m, k)| = \sqrt{\text{Re}^2[X(m, k)] + \text{Im}^2[X(m, k)]} \quad (3.5)$$

对数功率谱密度:

$$S_{\text{dB}(m,k)} = 20 \log_{10} \left(\frac{|X(m, k)|}{|X|_{\text{max}}} \right) \quad (3.6)$$

其中 $|X|_{\text{max}}$ 为幅度谱的最大值, 用于归一化。

3.3 Mel 频率变换

梅尔频谱是基于 STFT 得到的频谱，通过 Mel 滤波器组将频谱能量映射到 Mel 尺度上，模拟人耳听觉特性[4]。本项目目标是对环境声音进行分类识别，以便将来进一步对环境噪声进行分析和处理，因此对于环境噪声的识别应当符合人类对声音的感知。传统的线性频谱不能很好地反映人耳对声音的主观感知，Mel 频谱则通过非线性变换（见下文）更贴合听觉系统。具体优势分析可见数据处理章节。

Mel 频谱的计算流程为：将 STFT 处理后的信号通过 Mel 滤波器组和能量积分得到 Mel 谱图。

3.3.1 Mel 刻度转换

Mel 刻度基于人耳听觉感知特性[4]，其与线性频率的转换关系为：

$$m = 2595 \log_{10} \left(1 + \frac{f}{700} \right) \quad (3.7)$$

$$f = 700 \left(10^{\frac{m}{2595}} - 1 \right) \quad (3.8)$$

其中 m 为 Mel 频率， f 为线性频率（Hz）。

3.3.2 Mel 滤波器组设计

Mel 滤波器组由 $M = 128$ 个三角形带通滤波器组成[5]，第 i 个滤波器的频率响应为：

$$H_{i(k)} = \begin{cases} 0 & \text{if } f[k] < f[i-1] \\ \frac{f[k]-f[i-1]}{f[i]-f[i-1]} & \text{if } f[i-1] \leq f[k] \leq f[i] \\ \frac{f[i+1]-f[k]}{f[i+1]-f[i]} & \text{if } f[i] \leq f[k] \leq f[i+1] \\ 0 & \text{if } f[k] > f[i+1] \end{cases} \quad (3.9)$$

其中 $f[k] = k \cdot \frac{f_s}{N}$ 为第 k 个频率 bin 对应的频率， $f[i]$ 为第 i 个滤波器的中心频率。

3.3.3 Mel 频谱计算

Mel 频谱通过滤波器组与 STFT 功率谱的卷积得到[5]：

$$M(m, i) = \sum_{k=0}^{\frac{N}{2}} H_{i(k)} \cdot |X(m, k)|^2 \quad (3.10)$$

对数 Mel 频谱:

$$M_{\text{dB}(m,i)} = 10 \log_{10} \left(\frac{M(m,i)}{M_{\text{max}}} \right) \quad (3.11)$$




图 3.3.2: Mel 滤波器组示意图

3.4 机器学习模型

为了得到更好的分类效果，我们采用了几种经典的机器学习模型进行训练。以下是每种模型的数学原理和实现细节。

3.4.1 卷积神经网络 (CNN) 模型

采用深度卷积神经网络进行特征学习和分类[6], [7]，网络结构如下：

输入层：

$$\mathbf{X}_{\text{input}} \in \mathbb{R}^{B \times H \times W \times C} \quad (3.12)$$

其中 B 为批次大小， $H = 128$ (Mel 频道数)， $W = 216$ (时间帧数)， $C = 1$ (通道数)。

卷积层：第 l 层卷积操作[8]：

$$\mathbf{Y}^{(l)} = \sigma(\mathbf{W}^{(l)} * \mathbf{X}^{(l-1)} + \mathbf{b}^{(l)}) \quad (3.13)$$

其中 $*$ 表示卷积操作， σ 为 ReLU 激活函数：

$$\sigma(x) = \max(0, x) \quad (3.14)$$

池化层：最大池化操作[8]：

$$y_{i,j}^{(l)} = \max_{p,q \in P_{i,j}} x_{p,q}^{(l-1)} \quad (3.15)$$

其中 $P_{i,j}$ 为池化窗口区域。

全连接层：

$$z^{(l)} = \sigma(\mathbf{W}^{(l)} \mathbf{x}^{(l-1)} + \mathbf{b}^{(l)}) \quad (3.16)$$

输出层：采用 Softmax 函数进行多分类：

$$p_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad (3.17)$$

其中 $K = 50$ 为类别总数。

3.4.2 ResNet 残差网络模型

ResNet 通过引入残差连接解决深度网络的梯度消失问题[9]，其核心思想是学习残差映射而非直接映射。

残差块设计：残差块的数学表达式为：

$$\mathbf{Y} = \mathbf{F}(\mathbf{X}, \{\mathbf{W}_i\}) + \mathbf{X} \quad (3.18)$$

$$\mathbf{H} = \sigma(\mathbf{Y}) \quad (3.19)$$

其中 $\mathbf{F}(\mathbf{X}, \{\mathbf{W}_i\})$ 为残差映射， $\mathbf{X}$ 为恒等映射（跳跃连接）。

残差映射：

$$\mathbf{F}(\mathbf{X}) = \mathbf{W}_2 \sigma(\mathbf{W}_1 \mathbf{X} + \mathbf{b}_1) + \mathbf{b}_2 \quad (3.20)$$

当输入输出维度不匹配时，采用 1×1 卷积进行维度调整：

$$\mathbf{Y} = \mathbf{F}(\mathbf{X}) + \mathbf{W}_s \mathbf{X} \quad (3.21)$$

其中 $\mathbf{W}_s$ 为 1×1 卷积权重矩阵。

批量归一化：

$$\hat{\mathbf{x}} = \gamma \frac{\mathbf{x} - \mu}{\sqrt{\sigma^2 + \varepsilon}} + \beta \quad (3.22)$$

其中 μ 和 σ^2 分别为批次均值和方差， γ 和 β 为可学习参数。

3.4.3 注意力机制网络模型

注意力机制能够自适应地关注频谱图中的重要区域[10]，提升模型对关键特征的感知能力。

自注意力机制：给定输入特征图 $\mathbf{X} \in \mathbb{R}^{H \times W \times D}$ ，首先将其重塑为序列形式 $\mathbf{X}' \in \mathbb{R}^{N \times D}$ ，其中 $N = H \times W$ 。

查询、键、值矩阵的计算：

$$\mathbf{Q} = \mathbf{X}' \mathbf{W}^Q \quad (3.23)$$

$$\mathbf{K} = \mathbf{X}' \mathbf{W}^K \quad (3.24)$$

$$\mathbf{V} = \mathbf{X}' \mathbf{W}^V \quad (3.25)$$

其中 $\mathbf{W}^Q, \mathbf{W}^K, \mathbf{W}^V \in \mathbb{R}^{D \times d_k}$ 为可学习的投影矩阵。

注意力权重计算：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right) \mathbf{V} \quad (3.26)$$

注意力分数的计算：

$$\alpha_{i,j} = \frac{\exp\left(\mathbf{q}_i \cdot \frac{\mathbf{k}_j}{\sqrt{d_k}}\right)}{\sum_{l=1}^N \exp\left(\mathbf{q}_i \cdot \frac{\mathbf{k}_l}{\sqrt{d_k}}\right)} \quad (3.27)$$

输出特征：

$$\mathbf{o}_i = \sum_{j=1}^N \alpha_{i,j} \mathbf{v}_j \quad (3.28)$$

3.4.4 孪生网络模型

孪生网络通过共享权重的子网络学习输入的特征表示[11]，能够有效提取可比较的特征向量。

共享特征提取器：设计共享的特征提取网络 $f_{\theta(\mathbf{x})}$ ，其中 θ 为共享参数：

$$\mathbf{h} = f_{\theta(\mathbf{x})} \quad (3.29)$$

特征提取网络结构：

$$f_{\theta(\mathbf{x})} = f_4(f_3(f_2(f_1(\mathbf{x})))) \quad (3.30)$$

其中每个 f_i 代表一个卷积块：

$$f_{i(\mathbf{x})} = \text{MaxPool}\left(\text{ReLU}\left(\text{BatchNorm}\left(\text{Conv}_{i(\mathbf{x})}\right)\right)\right) \quad (3.31)$$

特征相似度计算：对于两个输入 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ ：

$$\mathbf{h}_1 = f_{\theta}(\mathbf{x}_1) \quad (3.32)$$

$$\mathbf{h}_2 = f_{\theta}(\mathbf{x}_2) \quad (3.33)$$

欧几里德距离:

$$d(\mathbf{h}_1, \mathbf{h}_2) = \|\mathbf{h}_1 - \mathbf{h}_2\|_2 \quad (3.34)$$

余弦相似度:

$$\text{sim}(\mathbf{h}_1, \mathbf{h}_2) = \frac{\mathbf{h}_1 \cdot \mathbf{h}_2}{\|\mathbf{h}_1\|_2 \|\mathbf{h}_2\|_2} \quad (3.35)$$

分类头设计:

$$\mathbf{p} = \text{softmax}(\mathbf{W}_{\text{cls}} \mathbf{h} + \mathbf{b}_{\text{cls}}) \quad (3.36)$$

3.4.5 损失函数

采用交叉熵损失函数[8]:

$$L = - \sum_{i=1}^N \sum_{j=1}^K y_{i,j} \log(\hat{y}_{i,j}) \quad (3.37)$$

其中 $y_{i,j}$ 为真实标签的 one-hot 编码, $\hat{y}_{i,j}$ 为模型预测概率。

3.4.6 优化算法

采用 Adam 优化器进行参数更新[12]:

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \mathbf{g}_t \quad (3.38)$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2) \mathbf{g}_t^2 \quad (3.39)$$

$$\hat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1 - \beta_1^t} \quad (3.40)$$

$$\hat{\mathbf{v}}_t = \frac{\mathbf{v}_t}{1 - \beta_2^t} \quad (3.41)$$

$$\theta_t = \theta_{t-1} - \alpha \cdot \frac{\hat{\mathbf{m}}_t}{\sqrt{\hat{\mathbf{v}}_t} + \varepsilon} \quad (3.42)$$

其中 $\alpha = 0.001$ 为学习率, $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\varepsilon = 10^{-8}$ 。

3.4.7 模型复杂度对比

模型类型	参数量	计算复杂度	特点
Simple CNN	0.41M	$O(N^2)$	基础卷积结构，计算高效
ResNet	10.69M	$O(N^2)$	残差连接，解决梯度消失
Attention	1.69M	$O(N^2)$	自适应特征权重，关注重点区域
Siamese	1.62M	$O(N^2)$	共享权重，特征表示学习

图 3.4.2: 不同模型的复杂度对比

4 数据分析处理

4.1 ESC-50 数据集概述

4.1.1 数据集基本信息

ESC-50 数据集是环境声音分类领域的标准基准数据集[13]，包含 2000 条环境音频记录，每条音频时长为 5 秒，采样率为 44.1kHz。数据集涵盖 50 个语义类别，每个类别包含 40 个样本，按照声音来源特性可归类为 5 个主要大类：

动物	自然音景	人类非语音	室内声音	室外噪音
狗叫声	雨声	婴儿哭声	门铃声	直升机声
公鸡叫	海浪声	打喷嚏	鼠标点击	电锯声
猪叫声	篝火声	鼓掌声	键盘敲击	警笛声
牛叫声	蟋蟀声	呼吸声	门板吱声	汽车喇叭
青蛙叫	鸟鸣声	咳嗽声	开罐声	引擎声
猫叫声	水滴声	脚步声	洗衣机声	火车声
母鸡叫	风声	笑声	吸尘器声	教堂钟声
昆虫声	倒水声	刷牙声	闹钟声	飞机声
绵羊叫	冲水声	鼾声	钟表声	烟花声
乌鸦叫	雷雨声	啜饮声	玻璃碎声	电锯切割声

图 4.1.3: ESC-50 数据集类别分布

4.1.2 声学特征分析标准

根据不同声音类别的物理特性，建立声学特征分析标准[14]:

类别	频率特征	时间特征	典型示例
人声	基频 50-400Hz，谐波丰富	稳态与瞬态交替	笑声、咳嗽
物理噪声	宽频带（20Hz-20kHz）	持续稳态	交通、机械声
动物噪声	谐波结构明显，频带跳跃	短时脉冲特性	鸟鸣、蛙叫

图 4.1.4: 声学特征分析标准

4.2 数据预处理流程

4.2.1 信号预处理步骤

- 数据预处理采用标准化流程，确保输入信号的一致性[1]:
1. 音频加载：使用 LibROSA 库加载音频文件，统一采样率为 22.05kHz
 2. 长度标准化：截取或零填充至固定长度（5 秒 = 110,250 采样点）
 3. 幅度归一化：将信号幅度范围标准化至[-1, 1]

4.2.2 时频变换处理

信号处理流程如下[15]:

1 原始音频 → 分帧加窗 → FFT变换 → STFT频谱 → Mel滤波 → Mel频谱

关键参数设置：

- 窗函数：Hann 窗，长度 $N = 2048$
- 帧移： $H = 512$ （约 23ms）
- Mel 滤波器数量： $M = 128$

4.3 典型声音类别对比分析

4.3.1 人声类音频分析

选取多人笑声音频作为人声类代表，该类音频具有明显的基频和谐波结构特征。




图 4.3.4: STFT 频谱图




图 4.3.5: Mel 频谱图

特征类型	STFT 频谱特征	Mel 频谱特征
频率分布	基频区域（100-300Hz）能量高度集中	基频带（44-500Hz）能量占比超过 60%
结构特征	谐波结构呈现清晰的垂直条纹分布	谐波结构在低频带得到良好保留
噪声特征	背景噪声主要分布在高频段（>4kHz）	高频带（1400-2000Hz）背景噪声衰减 40%
特征维度	1025 维完整频谱信息	128 维压缩特征表示

4.3.2 物理噪声类音频分析

选取锯木声音频作为物理噪声代表，该类音频具有宽频带能量分布特征。




图 4.3.7: STFT 频谱图




图 4.3.8: Mel 频谱图

特征类型	STFT 频谱特征	Mel 频谱特征
频率分布	全频段（20Hz-8kHz）能量分布相对平坦	低频带（20-1000Hz）能量占比超过 70%
结构特征	频谱结构复杂，缺乏明显的周期性模式	突出低频主要特征成分
噪声特征	低频谐波（< 500Hz）存在明显能量波动	高频带（2000-4000Hz）噪声能量衰减 55%
特征维度	1025 维宽频带信息	128 维紧凑特征表示

4.3.3 动物噪声类音频分析

选取青蛙叫声和昆虫声混合音频作为动物噪声代表，该类音频具有多频段峰值特征。




图 4.3.10: STFT 频谱图




图 4.3.11: Mel 频谱图

特征类型	STFT 频谱特征	Mel 频谱特征
频率分布	多个频段出现明显能量峰值（如 2kHz 谐波）	主频带（1000-2000Hz）能量占比超过 65%
结构特征	时间维度上呈现间歇性爆发模式	有效保留动物声音的关键识别特征
噪声特征	短时脉冲干扰主要分布在高频段（>10kHz）	高频噪声带（2000-4000Hz）能量衰减 60%
特征维度	1025 维详细频谱信息	128 维关键特征提取

4.4 Mel 滤波器效果评估

4.4.1 优势分析

生物适配性：Mel 滤波器模拟人耳听觉感知特性[4]，对于包含语音成分的环境声音具有更好的特征表达能力，有效提升语音类声音的识别准确率。

特征压缩效果：将 STFT 的 1025 维特征压缩至 128 维 Mel 特征，压缩比达到 87.5%。显著提升计算效率，减少约 8 倍的特征维度，在保留关键频谱信息的同时减少了存储需求。

噪声抑制性能：

噪声类型	抑制效果
物理噪声	高频段（>8kHz）能量衰减>50%
动物噪声	非主频带噪声抑制率>60%
人声背景噪声	高频背景噪声衰减 40%

4.4.2 局限性分析

- 信息损失:
- 高频细节信息丢失（动物噪声 10kHz 脉冲特征衰减 30%）
 - 瞬态事件（如撞击声、爆破声）可能被平滑处理
 - 某些快速变化的频谱特征可能被忽略

- 静态噪声残留:
- 持续稳态噪声（如交通噪声）在低频 Mel 频道（2-4）仍存在能量残留
 - 对于宽频噪声的抑制效果有限
 - 需要结合其他降噪技术进一步优化

4.4.3 特征提取效果量化

评估指标	数值	效果说明
特征维度压缩率	87.5%	大幅减少计算复杂度
关键频带能量保留率	>60%	保持声音识别关键信息
高频噪声抑制率	40%-60%	有效减少高频干扰
计算效率提升	约 8 倍	显著提升处理速度
存储空间节省	87.5%	减少内存和存储需求

图 4.4.9: Mel 滤波器量化效果评估

这些结果表明，Mel 频谱变换能够有效平衡特征表达能力与计算效率，为后续的机器学习模型提供了优质的输入特征。

4.5 数据处理结论

- 基于上述分析，Mel 频谱特征在环境声音分类任务中具有以下优势：
- (1) 符合听觉感知：模拟人耳特性，提升感知相关特征的表达能力
 - (2) 高效特征压缩：大幅降低特征维度，提升系统效率
 - (3) 有效噪声抑制：对多种类型噪声具有良好的抑制效果
 - (4) 类别区分性强：不同声音类别在 Mel 域具有明显的特征差异
- 这些特性使得 Mel 频谱成为环境声音分类系统的理想特征表示方法。

5 模型训练评估

5.1 评估指标体系

为全面评估模型在环境声音分类任务中的性能，本研究采用多维度评估指标体系 [16]，确保评估结果的客观性和全面性。

5.1.1 分类性能指标

准确率 (Accuracy): 表示模型正确分类的样本占总样本的比例:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (5.43)$$

其中 TP 、 TN 、 FP 、 FN 分别表示真正例、真负例、假正例、假负例。

精确率 (Precision): 表示被模型判定为正类中实际为正类的比例:

$$\text{Precision} = T \frac{P}{TP + FP} \quad (5.44)$$

召回率 (Recall): 表示实际为正类的样本中被模型正确识别的比例:

$$\text{Recall} = T \frac{P}{TP + FN} \quad (5.45)$$

F1 分数 (F1-Score): 精确率和召回率的调和平均数，综合反映模型性能:

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (5.46)$$

宏平均 F1 分数: 对于多分类问题，计算各类别 F1 分数的算术平均:

$$\text{Macro-F1} = \frac{1}{K} \sum_{i=1}^K \text{F1}_i \quad (5.47)$$

其中 $K = 50$ 为类别总数。

5.1.2 混淆矩阵分析

采用混淆矩阵可视化分类结果，矩阵元素 $C_{i,j}$ 表示真实类别为 i 但被预测为类别 j 的样本数量:

$$C_{i,j} = \sum_{k=1}^N I(y_k^{\text{true}} = i \text{ and } y_k^{\text{pred}} = j) \quad (5.48)$$

其中 $I(\cdot)$ 为指示函数， N 为测试样本总数。

5.2 实验设置

5.2.1 数据集划分

ESC-50 数据集按照 8:1:1 的比例随机划分为训练集、验证集和测试集：

数据集	样本数	比例	用途
训练集	1600	80%	模型参数学习
验证集	200	10%	超参数调优
测试集	200	10%	最终性能评估

图 5.2.10: 数据集划分详情

5.2.2 训练配置参数

设定统一的训练配置：

参数名称	数值	说明
优化器	Adam	自适应学习率优化
初始学习率	0.001	基于经验设定
批次大小	32	平衡内存与梯度稳定性
最大训练轮数	200	充分训练保证
Dropout 率	0.5	防止过拟合
早停耐心值	10	连续 10 轮无改善则停止
学习率衰减	ReduceLROnPlateau	验证损失停滞时衰减

图 5.2.11: 模型训练超参数配置

5.2.3 正则化策略

为防止过拟合，采用多种正则化技术[17]：

1. **Dropout** 正则化：在全连接层前添加 dropout 层，随机丢弃 50% 的神经元连接
2. 批量归一化：在卷积层后添加 BatchNorm 层，稳定训练过程
3. 早停机制：监控验证集损失，防止过度训练
4. 权重衰减：L2 正则化系数设为 10^{-4}

5.3 训练过程分析

5.3.1 损失函数收敛性

各模型在训练过程中的损失函数变化趋势如下：




图 5.3.13: Simple CNN 训练曲线




图 5.3.14: ResNet 训练曲线




图 5.3.15: Attention 模型训练曲线




图 5.3.16: Siamese 网络训练曲线

图 5.3.12: 各模型训练过程损失与准确率变化

5.3.2 收敛特性分析

通过训练曲线分析，各模型呈现以下特征：

模型	收敛轮数
Simple CNN	45
ResNet	60
Attention	30
Siamese	40

图 5.3.12: 各模型训练收敛特性对比

5.4 性能评估结果

5.4.1 整体性能对比

在测试集上的综合性能评估结果：

模型	Accuracy	Precision	Recall	F1-Score
Simple CNN	70.0%	73.0%	70.0%	69.0%
ResNet	73.0%	74.0%	73.0%	72.0%
Attention	74.0%	77.0%	74.0%	73.0%
Siamese	80.0%	83.0%	80.0%	80.0%

图 5.4.13: 各模型在测试集上的性能指标对比




图 5.4.17: 模型性能对比可视化图表

5.5 模型复杂度分析

5.5.1 计算复杂度对比

从理论计算复杂度和实际推理时间两个维度评估模型效率：

模型	参数量	推理时间 (s/epoch)
Simple CNN	0.41M	1.10
ResNet	10.69M	1.89
Attention	1.69M	2.78
Siamese	1.62M	1.68

图 5.5.14: 各模型计算复杂度与资源消耗对比

5.5.2 效率-性能平衡分析

定义效率-性能比值来量化模型的综合优势：

$$\text{Efficiency-Performance Ratio} = \frac{\text{F1-Score}}{\text{Parameters(M)} \times \text{Inference Time(s/epoch)}} \tag{5.49}$$

其中综合代价反映模型的整体计算成本，效率比值越高表示模型在单位计算成本下的性能表现越好。

模型	F1-Score	综合代价	效率比
Simple CNN	0.69	0.451	1.530
ResNet	0.72	20.204	0.036
Attention	0.73	4.698	0.155
Siamese	0.80	2.722	0.294

图 5.5.15: 模型效率-性能综合评估

5.5.3 性能优势分析

通过实验结果分析，各模型表现出以下特点：

Siamese

- 性能全面领先：F1-Score 达到 0.80，在所有指标上均为最优
- 共享权重机制：有效提取可比较的特征表示，减少参数冗余
- 对比学习策略：增强特征判别能力，提升类间分离度
- 效率平衡：在高性能与合理计算成本间取得最佳平衡（效率比 0.294）

Attention

- 精确率突出：在精确率指标上表现优异（77%），F1-Score 为 0.73
- 自适应权重：智能关注关键频谱区域，突出重要特征
- 模型解释性：可视化注意力权重，增强可解释性
- 推理效率：推理时间较长（2.78s/epoch），影响实际部署

ResNet

- 梯度流优化：残差连接有效解决深度网络梯度消失问题
- 性能中等：F1-Score 为 0.72，相比 Simple CNN 有改善
- 计算开销高：参数量达 10.69M，综合代价最高（20.204）
- 效率比最低：仅为 0.036，性价比不佳

Simple CNN

- 效率最优：效率比高达 1.530，计算成本最低
- 结构简洁：参数量仅 0.41M，推理时间 1.10s/epoch
- 性能基础：F1-Score 为 0.69，提供性能下界参考
- 实用价值：在极度资源受限环境下仍具备应用价值

模型	性能等级	效率等级	参数规模	综合评价
Siamese	优秀 (0.80)	良好 (0.294)	中等 (1.62M)	最佳平衡
Attention	良好 (0.73)	中等 (0.155)	中等 (1.69M)	可解释性强
Simple CNN	基础 (0.69)	优秀 (1.530)	极小 (0.41M)	资源友好
ResNet	中等 (0.72)	较低 (0.036)	大型 (10.69M)	计算密集

图 5.5.16: 各模型综合特征对比矩阵

5.5.4 误分类分析

通过混淆矩阵分析，我们对各模型的分类错误模式进行了深入研究。混淆矩阵能够直观显示模型在各类别上的分类准确性以及易混淆的类别组合。




图 5.5.19: Simple CNN 混淆矩阵




图 5.5.20: ResNet 混淆矩阵




图 5.5.21: Attention 模型混淆矩阵




图 5.5.22: Siamese 网络混淆矩阵

图 5.5.18: 各模型混淆矩阵对比分析

5.5.5 改进方向

基于实验结果，提出以下优化建议：

数据层面改进：

- 采用 SpecAugment 等音频数据增强技术
- 引入多尺度时频表示融合
- 收集更高质量的训练样本
- 平衡各类别的样本分布

模型架构改进：

- 探索 Transformer 架构在音频分类中的应用
- 设计多模态融合的网络结构
- 引入对抗训练提升模型鲁棒性
- 优化注意力机制的计算效率

训练策略改进：

- 采用课程学习策略渐进训练
- 引入知识蒸馏技术压缩模型
- 使用集成学习融合多个模型
- 设计更适合音频任务的损失函数

5.6 本章小结

本章通过系统的实验设计和全面的性能评估，对四种环境声音分类模型进行了深入分析。实验结果表明：

(1) **Siamese** 网络表现最优：在准确率（80%）、F1 分数（80%）等指标上均领先其他模型，验证了对比学习在音频特征提取中的有效性。

(2) **Attention** 机制具有潜力：在精确率方面表现突出，证明了注意力机制在音频关键区域定位中的价值。

(3) 模型复杂度与性能平衡：Siamese 网络在保持较高性能的同时，具有相对较低的计算复杂度。

这些结果为环境声音分类模型的选择和优化提供了重要的实验依据和理论指导。

6 感想

陈政宇（项目总体架构设计、论文撰写）：

作为项目的总体架构设计者，这次环境声音分类实验让我深刻体会到了系统性思维的重要性。从最初的需求分析、技术选型到最终的系统实现，每一个环节都需要统筹考虑。

在架构设计过程中，我认识到模块化设计的价值。我们将整个系统分解为数据预处理、特征提取、模型训练和性能评估四个核心模块，每个模块都具有明确的输入输出接口，这不仅便于团队协作，也为后续的功能扩展奠定了基础。特别是在机器学习模块设计中，我们采用了可配置的参数化接口，使得不同机器学习模型可以快速验证和比较。

论文撰写过程中，我深深感受到技术表达的挑战性。如何将复杂的 STFT 变换和 Mel 滤波器组的数学原理用清晰易懂的语言表达出来，如何平衡技术深度与可读性，这些都需要反复斟酌。通过大量文献调研，我学会了如何构建完整的技术叙述框架，从理论基础到实验验证的逻辑链条必须环环相扣。

最让我印象深刻的是实验结果的意外性。最初我们预期 ResNet 会在深度特征提取方面表现最佳，但实验结果显示 Siamese 网络的综合表现更优。这提醒我在系统设计时不能过度依赖先验假设，必须通过充分的实验验证来指导决策。

这次项目也让我认识到跨学科知识的重要性。环境声音分类不仅涉及信号处理和机器学习，还需要了解人因工程等领域的知识。Mel 频率刻度的设计就体现了人类听觉感知特性在技术实现中的应用，这种生物启发的工程设计思想值得深入学习。

程嘉耀（模型构建及数学推导）：

作为负责模型构建和数学推导的团队成员，这次实验让我对深度学习模型的设计原理有了更深层次的理解。

在数学建模过程中，我深刻体会到了理论与实践的差距。数学理论看似简洁，在实际实现时需要考虑窗函数选择、重叠率设置、零填充等众多工程细节。我学会了如何在数学严谨性和工程可行性之间找到平衡点。

模型架构设计是最具挑战性的部分。我理解了为什么这种架构能够学习到更具判别性的特征表示。相比传统的分类损失，对比损失直接优化特征空间中的距离度量，这为相似样本和不相似样本提供了更明确的优化目标。

在注意力机制的实现中，我对自注意力的数学机制有了全新认识。我理解了 softmax 归一化在保证权重概率分布特性中的作用。更重要的是，我学会了如何通过梯度分析来理解模型的学习动态，这对调试复杂网络架构非常有帮助。

残差连接的数学分析让我认识到网络深度与性能的非线性关系。我理解了残差连接如何缓解梯度消失问题，但在音频任务中，这种深度优势并不总是转化为性能提升，这提醒我模型设计必须考虑具体任务特性。

这次经历让我认识到数学建模不仅是工具，更是思维方式。通过严格的数学推导，我能够预测模型行为、分析失效模式、指导超参数调优，这种量化分析能力对于深度学习研究至关重要。

甘善铭（数据集处理及分析）：

作为数据集处理和分析的负责人，这次实验让我深刻认识到“数据为王”这一理念的重要性。

在 ESC-50 数据集分析过程中，我发现了许多有趣的现象。通过统计分析，我发现不同类别的音频长度分布存在显著差异，动物声音类别（如 frog、crickets）普遍较短，

而机械声音类别（如 engine、airplane）相对较长。这种不平衡分布对模型训练产生了微妙影响，促使我们采用了时间规整和数据增强策略。

特征提取的工程实现充满了挑战。Mel 滤波器组的构建看似简单，但在处理边界条件时需要格外小心。我深入研究了 librosa 库的实现细节，发现其在处理 Nyquist 频率附近的频点时采用了特殊的插值策略，这避免了频谱泄漏问题。这让我认识到工程实现的细节往往决定系统的最终性能。

数据预处理 pipeline 的设计让我学会了如何平衡效率与质量。最初我们采用了在线实时特征提取，但发现训练速度过慢。后来改为离线批量预处理并缓存特征，训练效率提升了 3 倍以上。这个经历让我深刻理解了 I/O 瓶颈在深度学习训练中的重要性。

在数据增强策略的探索中，我尝试了时间拉伸、音调变换、背景噪声添加等多种方法。最有效的是 SpecAugment 技术——在频谱图上随机遮掩时间段和频率段。这种方法的成功让我认识到，针对具体数据模态设计的增强策略往往比通用方法更有效。

数据质量分析是最具启发性的部分。通过人工听取和频谱可视化，我发现 ESC-50 中存在一些标注错误和边界模糊的样本。例如，某些“rain”样本实际包含了明显的“wind”成分，这种标注噪声解释了为什么某些类别容易混淆。这让我深刻认识到数据质量比数据数量更重要，高质量的小数据集往往比低质量的大数据集更有价值。

这次经历让我从一个全新角度理解了机器学习：模型只能学到数据中包含的信息，数据的质量和表示方式直接决定了模型性能的上限。

陈淦泉（机器学习模型训练与评估）：

通过本次音频分类实验，我不仅加深了对深度学习模型在实际任务中应用的理解，也进一步掌握了从数据预处理、模型训练到评估和可视化的完整流程。在实验过程中，我对不同类型的神经网络架构（如 CNN、ResNet、Attention 和 Siamese 网络）在音频信号处理中的表现差异有了直观的认识。尤其值得一提的是，在实验前我原以为较为复杂的模型（如 ResNet）一定会带来更好的效果，但实际结果显示，Siamese 网络在本任务中表现最为出色，这让我意识到模型选择应更贴合具体任务特点，而不仅仅依赖模型复杂度。同时，在模型训练过程中，参数设置（如学习率、batch size）、正则化策略（如 dropout）以及早停机制等，都对最终性能产生了显著影响，让我更加体会到训练策略的重要性。此外，在评估阶段，通过混淆矩阵、分类报告以及可视化工具对模型表现进行了深入分析，这些过程锻炼了我对模型“诊断”的能力，也让我意识到在准确率之外，精确率、召回率和 F1 分数等指标在衡量模型综合性能方面的重要性。总的来说，这次实验不仅提升了我的编程能力和模型调试技巧，也让我在实际操作中体会到了理论与实践的结合。未来我希望能继续探索更复杂的音频理解任务，如事件检测、语音识别等，并尝试更多创新型网络结构与优化策略。

7 参考文献

- [1] B. McFee *et al.*, “librosa: Audio and music signal analysis in python,” in *Proceedings of the 14th python in science conference*, 2015, pp. 18–25.
- [2] J. B. Allen and L. R. Rabiner, “A unified approach to short-time Fourier analysis and synthesis,” *Proceedings of the IEEE*, vol. 65, no. 11, pp. 1558–1564, 1977.
- [3] F. J. Harris, “On the use of windows for harmonic analysis with the discrete Fourier transform,” *Proceedings of the IEEE*, vol. 66, no. 1, pp. 51–83, 1978.
- [4] S. S. Stevens, J. Volkman, and E. B. Newman, “A scale for the measurement of the psychological magnitude pitch,” *The journal of the acoustical society of america*, vol. 8, no. 3, pp. 185–190, 1937.
- [5] S. Davis and P. Mermelstein, “Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences,” *IEEE transactions on acoustics, speech, and signal processing*, vol. 28, no. 4, pp. 357–366, 1980.
- [6] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [7] K. J. Piczak, “Environmental sound classification with convolutional neural networks,” in *2015 IEEE 25th International Workshop on Machine Learning for Signal Processing (MLSP)*, 2015, pp. 1–6.
- [8] I. Goodfellow, Y. Bengio, and A. Courville, *Deep learning*. MIT press, 2016.
- [9] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.
- [10] A. Vaswani *et al.*, “Attention is all you need,” *Advances in neural information processing systems*, vol. 30, 2017.
- [11] G. Koch, R. Zemel, R. Salakhutdinov, and others, “Siamese neural networks for one-shot image recognition,” in *ICML deep learning workshop*, 2015, p. 0.
- [12] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” *arXiv preprint arXiv:1412.6980*, 2014.
- [13] K. J. Piczak, “ESC: Dataset for environmental sound classification,” pp. 1015–1018, 2015.

- [14] D. Barchiesi, D. Giannoulis, D. Stowell, and M. D. Plumbley, “Acoustic scene classification: Classifying environments from the sounds they produce,” *IEEE Signal Processing Magazine*, vol. 32, no. 3, pp. 16–34, 2015.
- [15] M. Müller, *Fundamentals of music processing: Audio, analysis, algorithms, applications*. Springer, 2015.
- [16] D. M. Powers, “Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation,” *arXiv preprint arXiv:2010.16061*, 2011.
- [17] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, “Dropout: a simple way to prevent neural networks from overfitting,” *The journal of machine learning research*, vol. 15, no. 1, pp. 1929–1958, 2014.